

● ENTERPRISE AI & FINANCIAL QUANTITATIVE ENGINEERING

TensorFold + Gateway

智慧台股量化分析與聯網服務系統

DGX Spark 單機部署、本地 DuckDB 零拷貝極速分析、三層解耦微服務與維運實踐架構

⚡ 模型核心: Qwen 3.8 Flash Next (27B)

📊 數據庫: DuckDB In-Memory + 8 大 Parquet 庫

🌐 通訊協定: OpenAI-Compatible Tool Calling

📅 發布日期: 2026-10-02

三層解耦微服務架構 (Tri-Tier Microservices)

將前端對話介面、智慧網關代理、數據運算引擎與大模型推論核心徹底解耦，兼具彈性與毫秒級響應。

第一層：SearXNG

PORT 8080

全開源隱私型聚合聯網搜尋引擎

- ▶ 以 Docker 獨立容器常駐，無調用配額限制
- ▶ 啟用專屬 `JSON API` 格式輸出
- ▶ 主動提供財經即時新聞、重大公司訊息檢索
- ▶ 提供 Gateway 之 `web_search` 工具後端調用

響應速度

~0.6s

Docker Container

第二層：TensorFold Core

PORT 1235

GPU 加速 Qwen 3.8 Flash Next 推論本體

- ▶ 模型名稱: `huihui-qwen3.8-27b-abliterated`
- ▶ 上下文深度: `262,144 tokens` (256K 超長窗口)
- ▶ KV 快取最佳化: `int8` + `--ple-on-ssd`
- ▶ 啟用 `MTP Drafts` 多推測投機解碼，極致吞吐
- ▶ 全域鎖定 `--no-thinking`，消除不必要延遲

推論解碼速率

40+ T/s

DGX Spark CUDA

第三層：Smart Gateway

PORT 1234

智慧量化分析反向代理與 Tool Calling 網關

- ▶ 標準 OpenAI 相容介面 (`/v1/chat/completions`)
- ▶ 內嵌 **DuckDB** 向量化查詢引擎，零拷貝分析
- ▶ 後端自律代理循環 (Autonomous Agent Loop)
- ▶ 自動合成安全 SSE 串流，前端客戶端無感整合
- ▶ 防護限制：唯讀查詢安全過濾，杜絕高危險指令

客戶端連線埠

1234

Python + DuckDB

本地台股 8 大核心量化數據庫在庫檢視

儲存於 `/home/blue/stock_data/`，採用標準 Apache Parquet 列式儲存，DuckDB 毫秒級掛載。

籌碼與衍生品數據集

主力量化核心

數據集名稱	檔案規格	檔案數	核心欄位 / 功能
券商分點日報 broker_trade	<code>api_absr1_*.parquet</code> <code>api_absr1_*.xlsx</code>	85 個交易日檔 1 檔	分點買賣超股數、均價；已關聯 935 筆券商中文名稱字典。
融資融券與券資比 margin	<code>api_margin_*.parquet</code>	68 個交易日檔	資券餘額、增減、券資比 (<code>short_margin_ratio_pct</code>)、資券互抵。
期貨多空部位 taifex	<code>api_taifex_*.parquet</code>	68 個交易日檔	外資/投信/自營商台指期留倉、散戶小台多空比率 (<code>retail_mtx_ratio_pct</code>)。
庫藏股最新快照 treasury_stock	<code>treasury_stocks_latest.parquet</code>	即時快照	全市場進行中與歷史庫藏股買回區間、預計/已買回股數、執行進度。

行情、股權與基本面數據集

長線與基本面

數據集名稱	檔案規格	檔案數	核心欄位 / 功能
每日收盤行情 close_price	<code>api_close1_*.parquet</code>	74 個交易日檔	開高低收、成交量值、漲跌幅；涵蓋上市與上櫃全市場標的。
集保千張大戶 tdcc	<code>api_tdcc_*.parquet</code>	5 個週報檔	每週五更新；千張大戶持股比例、人數與散戶持股比例變化。
全市場月營收 revenue	<code>api_revenue_????-??.parquet</code> <code>api_revenue_all.parquet</code>	93 個月份檔 1 檔	自 2019-01 至今全歷史；當月營收、累計營收、MoM%、YoY%。(9月申報中)
庫藏股每日時點檔 treasury_history	<code>treasury_stocks_YYYYMMDD.parquet</code>	每日時點	回溯每日買回進度、比對公司護盤進場時點與庫藏股實際達成率。

Gateway 自律代理循環與工具調用規格

模型在後端自主決策調用 SQL 查詢或聯網搜尋，無需前端客戶端支援 Function Calling。

註冊工具定義 (Native Tool Definitions)

OPENAI FUNCTION SCHEMA

▶ `query_stock_data`：執行 DuckDB SQL 查詢本地量化庫。

```
SELECT symbol, name, close, volume
FROM close_price
WHERE symbol = '2330'
ORDER BY trade_date DESC LIMIT 5;
```

▶ `get_stock_schema`：動態查詢 6 大資料表欄位定義與最新交易日。

▶ `web_search`：聯網調用 SearXNG 即時檢索新聞與事件背景。

自律代理執行流程 (Agent Execution Loop)

SERVER-SIDE LOOP

- ▶ **請求攔截**：接收客戶端請求，自動將台股資料庫現況與工具清單注入 System Prompt。
- ▶ **模型決策**：Qwen 3.8 評估問題，產生結構化 `tool_calls`（包含 SQL 語法與調用原因）。
- ▶ **本地秒級執行**：Gateway 執行 DuckDB 查詢（限制最多 100 筆與唯讀安全防護），並動態補齊券商中文分點名稱。
- ▶ **遞迴反饋**：將 `role: tool` 結果封裝，再次請求模型進行綜合量化解讀。
- ▶ **串流輸出**：將模型產出的最終量化報告以 SSE 流式格式傳回給前端（Cline / Chat UI）。

關鍵問題排查：Cline Socket 中斷錯誤根治

深入剖析 `SocketError: other side closed (UND_ERR_SOCKET)` 協議成因與代碼級修復方案。

根本成因剖析 (Root Cause)

PROTOCOL CONFLICT

- ▶ 客戶端環境：Cline (VS Code 擴充套件) 內部採用 Node.js 的 `undici` 作為 HTTP Client。
- ▶ HTTP/1.1 串流協定衝突：Gateway 原先發送 SSE 時帶有 `Connection: keep-alive` 標頭，但未傳送 `Content-Length` 亦未使用 `chunked` 分塊編碼。
- ▶ EOF 界定失敗：HTTP/1.1 規定無長度標頭的流必須透過 Server 主動關閉連線 (FIN) 界定結尾。Gateway 承諾了 `keep-alive` 卻未主動結束 Socket，導致 `undici` 在收到 `data: [DONE]` 後判定連線異常中斷。
- ▶ 營收資料重複：原通配符 `api_revenue_*.parquet` 同時匹配到切檔與全量庫，造成 2026-09 查詢出現雙倍重複。

修復成果與實測驗證 (Resolution)

PRODUCTION READY

- ▶ 標頭修正：將 SSE 標頭全面改為 `Connection: close`，與 TensorFlow 核心統一。
- ▶ 連線標記：在 `data: [DONE]` 輸出後明確設定 `self.close_connection = True`，發送標準 TCP FIN。
- ▶ 異常保護：Socket 寫入包覆 `BrokenPipeError` 與 `ConnectionResetError` 容錯。
- ▶ 營收防重：改為精確切檔通配符 `api_revenue_????-?.parquet`，徹底消除重複。
- ▶ 9 月營收驗證：確認 16 家提早申報公司 (毅嘉、德律、金麗科等) 檔案無損健康。

服務啟動自動化與維運實踐 (Operations)

針對 `start_web.sh` 與 `stop_web.sh` 進行全面強化，確保一鍵重啟 100% 穩定就緒。

啟動腳本強化

START_WEB.SH

提升執行穩定性與防呆機制：

- ▶ **Docker 權限封裝**：建立 `run_docker` 函式，自動在登入階段缺權限時透過 `sg docker` 執行。
- ▶ **殘留 Port 清理**：啟動前主動調用 `lsof -ti :1234` 釋放被佔用之孤兒進程。
- ▶ **守護程序獨立**：使用 `setsid + nohup`，終端機關閉不影響運行。

日常維運指令

CLI COMMANDS

常用標準維運操作：

```
# 一鍵啟動 / 重啟全部服務
./start_web.sh

# 停止所有服務 (Gateway + Docker)
./stop_web.sh

# 查看即時分析日誌
tail -f gateway.log
```

健康狀態探測

HEALTH CHECKS

即時驗證服務可用性：

```
# 1. 檢測 Gateway 與模型清單
curl http://127.0.0.1:1234/v1/models

# 2. 檢測 SearXNG 搜尋引擎
curl -s http://127.0.0.1:8080/

# 3. 測試 DuckDB 工具查詢
curl -X POST http://127.0.0.1:1234/v1/chat/completions
...
```

系統價值總結與後續演進藍圖

打造高精準、超低延遲、具備結構化資料庫理解能力的台股專屬私有化 AI 大腦。

核心價值亮點 (Key Deliverables)

COMPLETED

- ▶ 全自動量化工具調用：AI 主動判斷籌碼、資券、期貨、營收多維指標並給出策略建議。
- ▶ 超高速向量化計算：直接以 DuckDB 讀取 Parquet，無傳統關聯式資料庫匯入負擔。
- ▶ 分點中文名稱自關聯：自動匹配 935 筆券商代碼字典，擺脫枯燥數字代碼。
- ▶ 全域關閉思考鏈：消除無意義的推理輸出耗損，極致加速對話節奏。
- ▶ 協定穩定度提升：徹底解決 Cline 串流 Socket 斷線問題，開箱即用。

後續擴充方向 (Future Roadmap)

ROADMAP

- ▶ 全量營收庫自動重構：定期補齊歷史營收全量 Parquet 檔案並提供高速緩存。
- ▶ 進階主力分點指標庫：在 DuckDB 內建「前 5 大主力買超集中度」、「地緣券商異常交易」預算視圖。
- ▶ 多模型負載均衡 (Load Balancing)：針對併發需求加入多 GPU 執行個體分配支援。
- ▶ 通訊軟體即時告警整合：整合盤後自動主力大戶掃描，主動推播至 Line / Telegram。